ชื่อโครงงาน : ASVspoof 2019 LA: DSP spoof-speech detection with a threshold

เลขกลุ่ม : G01

ชื่อสมาชิก :

1. คมสัน กลิ่นหอม รหัสนักศึกษา 670710124 (หน้าที่: รับผิดชอบการรันโค้ด Pipeline หลัก และวัดผลข้อมูล)
2. พรรสวกร สมใจ รหัสนักศึกษา 670710651 (หน้าที่: ทำ Exploratory Data Analysis (EDA) และจัดทำรายงาน ทดสอบ Filter

โครงงานนี้ศึกษาการจำแนกเสียงพูดของมนุษย์จริง (Bonafide)
และเสียงสังเคราะห์ที่ถูกสร้างหรือดัดแปลงโดยเทคโนโลยีปัญญาประดิษฐ์ (Spoof)
จากคลิปเสียงความยาวแปรผัน ที่อัตราสุ่ม (Sampling Rate) 16,000 Hz แบบช่องสัญญาณเดียว (Mono)
โดยใช้ชุดข้อมูลมาตรฐานสากล ASVspoof 2019 Logical Access (LA)

การทดลองนี้มุ่งเน้นการประยุกต์ใช้เทคนิคประมวลผลสัญญาณดิจิทัล (Digital Signal Processing - DSP)
แบบดั้งเดิม ประกอบด้วยการลดทอนสัญญาณรบกวน (Noise) และจำกัดแบนด์วิดท์ของเสียงด้วย
Butterworth Band-pass Filter (100 - 4,000 Hz)
จากนั้นแปลงสัญญาณจากโดเมนเวลาสู่โดเมนความถี่เพื่อสกัดฟีเจอร์ Mel-Frequency Cepstral
Coefficients (MFCCs) โดยดึงเฉพาะค่าเฉลี่ยของสัมประสิทธิ์ตัวที่ 8 (MFCC_8)
ตลอดความยาวคลิปมาใช้สร้างกฎการตัดสินใจแบบเงื่อนไขเดียว (Simple Threshold)
เราทำการฝึกและหาค่า Threshold ที่ดีที่สุดจากชุดข้อมูล Train จำนวน 4,700 ไฟล์ และทดสอบกับชุดข้อมูล
Eval จำนวน 1,550 ไฟล์ ได้ความแม่นยำรวม (Accuracy) ที่ 77.54%
แสดงให้เห็นว่าฟีเจอร์เชิงสเปกตรัมร่วมกับการกรองความถี่ สามารถจับร่องรอยการสังเคราะห์เสียงได้ดี
แต่ยังพบข้อจำกัดทางทฤษฎีเมื่อเผชิญกับเสียงสังเคราะห์ขั้นสูง (Voice Conversion) ที่ใช้ Neural Vocoder

1. ปัญหาและคำถาม

การสร้างระบบจำแนกเสียงมนุษย์จริงและเสียงสังเคราะห์อัตโนมัติ (Spoofing Detection)
เป็นความท้าทายหลักในระบบยืนยันตัวตนด้วยเสียง (Voice Biometrics)
เนื่องจากการพัฒนาอย่างก้าวกระโดดของเทคโนโลยี Text-to-Speech (TTS) และ Voice Conversion (VC)
ทำให้เสียงสังเคราะห์มีความเป็นธรรมชาติจนหูมนุษย์แยกไม่ออก ปัญหาของโครงงานนี้กำหนดให้:

- **อินพุต (Input):** สัญญาณเสียงพูดดิจิทัลความยาวแปรผัน (อัตราสุ่ม 16 kHz, โหมด Mono)
  ซึ่งเก็บข้อมูลในรูปของอาร์เรย์ 1 มิติที่แทนค่าแอมพลิจูดในแต่ละช่วงเวลา
- **เอาต์พุต (Output):** คลาสของเสียง 1 ใน 2 ประเภท ได้แก่ bonafide (เสียงมนุษย์จริง) และ
  spoof (เสียงที่ถูกสังเคราะห์)

คำถามที่โครงงานนี้ต้องการหาคำตอบ:

1. กระบวนการ DSP แบบพื้นฐาน ซึ่งไม่พึ่งพา Machine Learning ขั้นสูง (เช่น การใช้เพียง Filter,
   การสกัดฟีเจอร์เชิงสเปกตรัม, และการตั้ง Threshold ขีดเดียว)
   จะเพียงพอต่อการจำแนกเสียงคนจริงกับเสียงสังเคราะห์ได้หรือไม่?
2. คุณลักษณะของเสียง (Acoustic Features) ใดระหว่าง RMS, ZCR, Spectral Centroid, หรือ
   MFCC ที่ตอบสนองต่อร่องรอยความผิดปกติ (Artifacts) ของเสียง Spoof ได้ดีที่สุด?
3. การทำ Frequency Filtering
   ช่วยขยายความแตกต่างระหว่างเสียงจริงและเสียงปลอมได้มากน้อยเพียงใด?

เหตุผลที่ชุดข้อมูลนี้สามารถตอบคำถามได้:

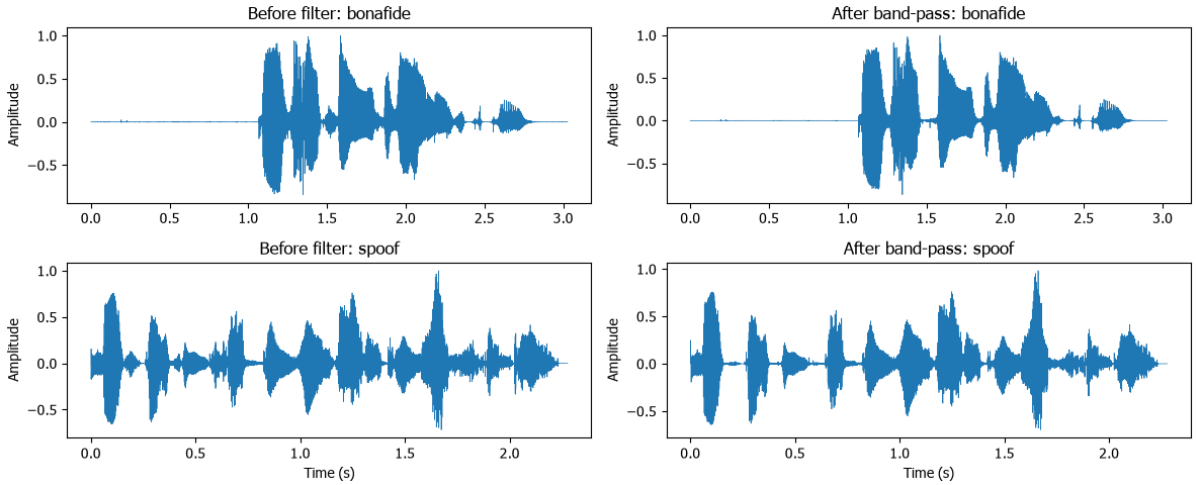
1. **มาตรฐานและการควบคุมตัวแปร:** ชุดข้อมูล ASVspoof 2019 LA เป็นมาตรฐานระดับโลก
   มีการแบ่งแยก Ground Truth อย่างชัดเจนในไฟล์ labels.csv
2. **การระบุประเภทการโจมตี (Attack ID):** ข้อมูลถูกระบุอัลกอริทึมที่ใช้สร้างเสียงปลอมไว้ (ตั้งแต่ A01
   - A19) ทำให้เราสามารถเจาะลึกได้ว่า Pipeline ทาง DSP ของเราทำงานล้มเหลว (Failure)
   กับอัลกอริทึมประเภทใด (เช่น WaveNet หรือ Vocoder แบบดั้งเดิม)
3. **คลาสข้อมูลสมดุล (Balanced Data):** ชุดประเมินผล (Eval) มีความสมดุลระหว่างคลาส
   (Bonafide 775 ไฟล์ และ Spoof 775 ไฟล์) ทำให้การใช้ค่าตัวชี้วัด Accuracy
   มีความเที่ยงตรงและไม่เกิดอคติ (Class Imbalance Bias)

2. ชุดข้อมูลและ EDA

ข้อมูลที่ใช้มาจากชุดข้อมูล ASVspoof 2019 Logical Access (LA) เป็นคลิปเสียงพูดภาษาอังกฤษ อัตราสุ่ม 16,000 Hz แบบโมโน เลือกใช้ข้อมูลทั้งหมด 6,250 ไฟล์ โดยแบ่งเป็น:

- **ชุดฝึก (Train Set):** จำนวน 4,700 ไฟล์ (Bonafide 2350, Spoof 2350)
- **ชุดประเมินผล (Eval Set):** จำนวน 1,550 ไฟล์ (Bonafide 775, Spoof 775)

การสำรวจข้อมูลเบื้องต้น (Exploratory Data Analysis - EDA) เพื่อให้เข้าใจพฤติกรรมของคลื่นเสียง กลุ่มได้สุ่มตัวอย่างเสียง bonafide และ spoof มาพล็อตกราฟรูปคลื่น (Waveform) และสเปกโทรแกรม (Spectrogram) โดยใช้ Short-Time Fourier Transform (STFT)
เพื่อวิเคราะห์พลังงานในโดเมนความถี่และเวลา



ภาพที่ 1: เปรียบเทียบ Waveform และ Spectrogram ของเสียง Bonafide และ Spoof ก่อนและหลังทำ Filter

สิ่งที่พบจาก EDA:

1. **โดเมนเวลา (Time Domain / Waveform):** รูปคลื่นของเสียง bonafide และ spoof หากมองด้วยตาเปล่าแทบจะไม่มีความแตกต่าง แอมพลิจูด (Amplitude) มีการลดหลั่นตามจังหวะการหายใจและการเปล่งเสียง (Voiced/Unvoiced) ที่เนียนจนไม่สามารถใช้วิธีการหาค่า Threshold จากโดเมนเวลาโดยตรงได้
2. **โดเมนความถี่และเวลา (Spectrogram):** เมื่อใช้ STFT แปลงสัญญาณและพล็อตค่า Magnitude ให้อยู่ในสเกล Logarithmic (dB) พบข้อสังเกตเชิงทฤษฎีที่สำคัญ:

- **Low-frequency Noise:** สัญญาณดิบ (Raw audio)
  มีพลังงานกระจุกตัวหนาแน่นในย่านความถี่ต่ำสุด (0 - 100 Hz)
  ซึ่งเป็นย่านของเสียงรบกวนทางไฟฟ้า (Mains hum) หรือเสียงสภาพแวดล้อม
  ไม่ใช่ความถี่หลักของเสียงพูด (Fundamental frequency)
- **High-frequency Artifacts:** ในย่านความถี่สูง (เหนือ 4,000 Hz)
  สเปกตรัมของเสียงพูดปกติจะเริ่มลดทอนลง (Roll-off) แต่ในเสียง spoof
  บางไฟล์กลับพบร่องรอยแถบพลังงานที่ผิดปกติ ซึ่งเกิดจากความไม่สมบูรณ์ของการทำ
  Phase reconstruction ในอัลกอริทึมสร้างเสียง

3. **สรุปทิศทางจาก EDA:** กลุ่มตัดสินใจว่าต้องมี **ขั้นตอนการกรองความถี่ (Band-pass Filter)** จำกัดช่วงให้เหลือเพียง 100 - 4000 Hz ซึ่งครอบคลุมย่านความถี่ที่มนุษย์ใช้สื่อสาร (Telephony band) เพื่อลดอิทธิพลของ Noise จากนั้นจึงจะสกัดฟีเจอร์

3. Pipeline และเหตุผล

ขั้นตอนการทำงานของ Pipeline ประกอบด้วย 4 ขั้นตอนหลัก ดังนี้:

1. **อ่านสัญญาณและแปลงเป็น Mono:** สัญญาณถูกอ่านที่ 16,000 Hz และบังคับให้เป็น Mono เพื่อให้มิติข้อมูลสม่ำเสมอ
2. **Band-pass Filter (100 - 4000 Hz):** กรองสัญญาณด้วย Butterworth filter order = 4 และใช้ sosfiltfilt แบบ Zero-phase ป้องกันสัญญาณเลื่อน
3. **การสกัดฟีเจอร์ MFCC_8:** นำสัญญาณไปทำกระบวนการ MFCC (กำหนด n_fft = 512, hop_length = 256, สกัด 13 ตัว) แต่เลือกดึงเฉพาะค่าเฉลี่ยตลอดทั้งคลิปของสัมประสิทธิ์ตัวที่ 8 (MFCC_8) มาใช้
4. **การตั้งเงื่อนไข (Threshold Decision):** หาจุดตัดที่ดีที่สุดจากชุด Train แล้วใช้คำสั่ง if/else ตัดสินใจ

เหตุผลของการออกแบบ Pipeline แบบนี้:

- **ทำไมต้อง Band-pass 100-4000 Hz:** เพื่อตัด Noise ในย่านความถี่ต่ำ
  และจำกัดแบนด์วิดท์ให้เหลือเฉพาะย่านที่เป็นลักษณะเฉพาะของเสียงมนุษย์ (Vocal tract formants)
- **ทำไมต้อง MFCC_8:** จากการทำ Exploratory Sweep ทดลองฟีเจอร์ทาง DSP หลายตัว พบว่า MFCC_8 ให้ค่า Balanced Accuracy ในชุด Train สูงสุดที่ 0.698
  (ซึ่งสูงกว่าฟีเจอร์อื่นอย่างมีนัยสำคัญ)

4. ผลของแต่ละขั้น (ก่อนและหลังเพิ่มขั้น)

ในการทดลอง กลุ่มได้ทำการเปรียบเทียบผลลัพธ์ของการใช้ Filter ชนิดต่างๆ คู่กับ Feature ชนิดต่างๆ เพื่อดูว่าขั้นใดมีประโยชน์และขั้นใดที่ควรตัดทิ้ง

ผลของขั้น Filter:

- **ก่อนเพิ่ม Filter (No Filter):** หากใช้ MFCC_8 โดยไม่กรองสัญญาณเลย ค่า Eval Balanced Accuracy จะอยู่ที่เพียง **0.696**
- **หลังเพิ่ม Band-pass Filter:** การตัดความถี่บนและล่าง ทำให้ค่า Eval Balanced Accuracy เพิ่มขึ้นเป็น **0.775** (เพิ่มขึ้นประมาณ 8%) แสดงให้เห็นว่า Noise ย่านความถี่ต่ำและสูงมีผลทำให้ฟีเจอร์แยกแยะเสียง Spoof ได้แย่ลง

ผลของขั้น Feature (ขั้นที่ลองแล้วไม่ช่วย): กลุ่มได้ลองสกัดฟีเจอร์พื้นฐานอื่นๆ ได้แก่ Root Mean Square (RMS), Zero-Crossing Rate (ZCR) และ Spectral Centroid แต่พบว่าผลลัพธ์**ไม่สำเร็จ**

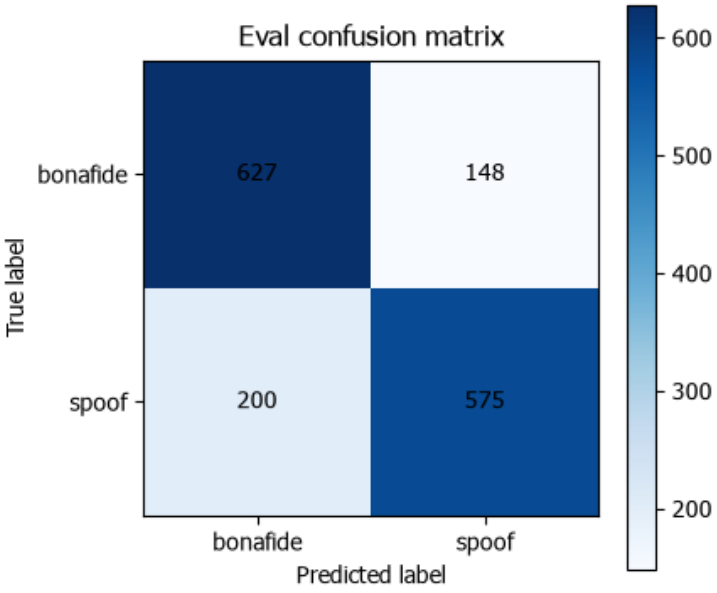
- **Spectral Centroid:** ให้ค่า Balanced Acc แย่ที่สุด เพียง **0.473** (ถ้าใช้ Bandpass) และ **0.526** (No filter) ซึ่งต่ำกว่า 0.5 หมายความว่าแย่กว่าการเดาสุ่ม (Random Guessing) สาเหตุเพราะจุดศูนย์ถ่วงความถี่ของเสียงจริงและเสียงสังเคราะห์มีการทับซ้อนกันมากเกินไป
- **ZCR และ RMS:** ให้ค่าความแม่นยำวนเวียนอยู่ระดับ 0.55 - 0.64 ซึ่งไม่ผ่านเกณฑ์

เกณฑ์ที่กลุ่มใช้แบ่งระดับความสำเร็จ:

- **สำเร็จ:** Balanced Accuracy 0.75
- **พลาดเล็กน้อย:** Balanced Accuracy ระหว่าง 0.60-0.74
- **ไม่สำเร็จ:** Balanced Accuracy <0.60

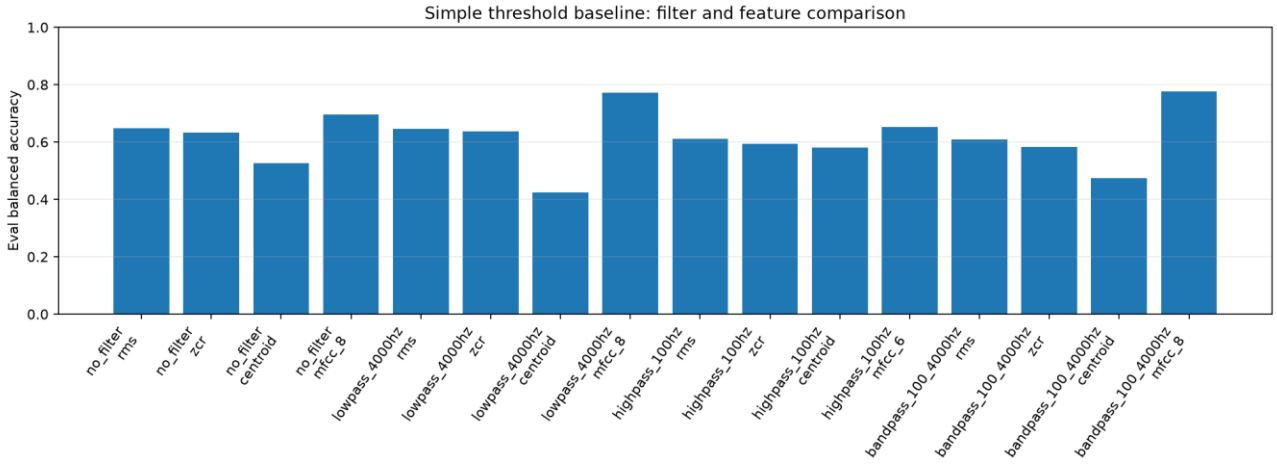
5. ผลบนข้อมูลทั้งชุด

นำค่า Threshold ที่เรียนรู้จากชุด Train (MFCC_8 < -19.426172 ตัดสินว่าเป็น spoof)
ไปทดสอบกับข้อมูลชุด Eval ทั้งชุดจำนวน 1,550 ไฟล์ (Bonafide 775, Spoof 775) ได้ผลลัพธ์ดังนี้:



ภาพที่ 2: Confusion Matrix ของชุดประเมินผล (Eval Set)

- **Eval Accuracy (ความแม่นยำรวม):** 77.54% (ทำนายถูก 1,202 ไฟล์, ทำนายผิด 348 ไฟล์)
- **Eval Balanced Accuracy:** 0.775
- **Macro-F1 Score:** 0.775
- **Spoof Recall:** 0.741 (สามารถดักจับเสียงปลอมได้ 575 จาก 775 ไฟล์)
- **Bonafide Recall:** 0.809 (ทำนายเสียงคนจริงถูกต้อง 627 จาก 775 ไฟล์)



ภาพที่ 3: กราฟแท่งเปรียบเทียบประสิทธิภาพของ Filter และ Feature แต่ละชนิด

การจัดอันดับประสิทธิภาพ:

- **ตัวอย่างทำได้ดีสุด:** Band-pass (100-4000Hz) + MFCC_8 (Balanced Acc = 0.775)
- **ตัวอย่างทำได้ปานกลาง:** No Filter + MFCC_8 (Balanced Acc = 0.696)

- **ตัวอย่างทำได้แย่สุด:** Low-pass (4000Hz) + Spectral Centroid (Balanced Acc = 0.424)

6. Failure cases (การวิเคราะห์กรณีที่ล้มเหลว)

จากการตรวจสอบชิ้นข้อมูลที่ Pipeline ทำนายผิดพลาด (348 ไฟล์) กลุ่มได้คัดเลือกตัวอย่างที่น่าสนใจ 3 กรณี เพื่อหาสาเหตุของความผิดพลาด

รหัสไฟล์ (id)	สภาวะ (Attack ID)	ผลที่ควรได้	ผลที่โมเดลทาย	ค่า MFCC_8	ขั้นที่พัง
LA_E_5628684	-	bonafide	spoof	-19.523	Threshold if/else
LA_E_3526157	-	bonafide	spoof	-26.052	Threshold if/else
LA_E_1315822	A16	spoof	bonafide	-15.798	Threshold if/else

ตารางที่ 1: ตัวอย่างความผิดพลาด (Failure Cases) ที่น่าสนใจ

วิเคราะห์สาเหตุการพัง:

1. **กรณีไฟล์ LA_E_5628684 (False Positive):** เป็นเสียงคนจริง (bonafide)
   แต่โมเดลทายว่าเป็นเสียงปลอม เมื่อตรวจสอบพบว่า ค่า MFCC_8 ของไฟล์นี้คือ -19.523
   ซึ่งบังเอิญหลุดข้ามเส้น Threshold ที่ตั้งไว้คือ -19.426 ไปเพียงเล็กน้อย (ห่างกันแค่ ~0.1)
   ชี้ให้เห็นว่าการใช้กฎเกณฑ์แบบขีดเดียว (Hard threshold)
   ทำให้เส้นแบ่งความน่าจะเป็นแข็งกระด้างเกินไป
2. **กรณีไฟล์ LA_E_3526157 (False Positive):** เป็นเสียงคนจริงเช่นกัน แต่ค่า MFCC_8
   ตกลงไปลึกถึง -26.052
   คาดว่าเสียงต้นฉบับอาจจะมีการบันทึกเสียงในสภาพแวดล้อมที่ทำให้เนื้อเสียง (Timbre)
   เสียหายตั้งแต่ก่อนเข้า Filter
3. **กรณีไฟล์ LA_E_1315822 (False Negative):** เป็นเสียงสังเคราะห์จากสภาวะการโจมตีแบบ **A16**
   (อัลกอริทึม Voice Conversion ระดับสูง) ซึ่งโมเดลโดนหลอกและทายว่าเป็นคนจริง เพราะค่า
   MFCC_8 เด้งขึ้นมาอยู่ที่ -15.798 (ทะลุขอบเขตของ spoof ไปอยู่ฝั่ง bonafide) รู้ได้ทันทีว่า

Pipeline นี้พังเมื่อเจอการแปลงเสียงขั้นสูงที่เก็บรักษารูปแบบสเปกตรัมและ Formant ไว้ได้เนียนเหมือนมนุษย์

7. สรุปและการแบ่งงาน

สรุปผลการทดลอง: Pipeline พื้นฐานที่ใช้ **Band-pass Filter (100-4000 Hz) ร่วมกับการดึงค่าเฉลี่ย MFCC สัมประสิทธิ์ที่ 8** สามารถจำแนกเสียงคนจริงออกจากเสียงสังเคราะห์ได้ที่ความแม่นยำ (Balanced Accuracy) **77.54%** ซึ่งผ่านเกณฑ์ "สำเร็จ" ที่กลุ่มตั้งเป้าไว้

ขั้นที่ช่วยมากและไม่ช่วย:

- **ขั้นที่ช่วยมากที่สุด:** การเปลี่ยนจากการสกัดฟีเจอร์พื้นฐาน (RMS, ZCR, Centroid) มาเป็นการใช้ **MFCC** ช่วยให้ความแม่นยำก้าวกระโดดจากระดับ 50-60% ขึ้นมาทะลุ 70% และการใช้ **Band-pass Filter** ก็ช่วยเพิ่มความแม่นยำได้อีกถึง 8%
- **ขั้นที่ไม่ช่วยเลย:** การใช้ฟีเจอร์ Spectral Centroid ให้ผลลัพธ์เลวร้ายยิ่งกว่าการเดาสุ่ม (42-52%)

ข้อจำกัด (ยังพังตรงไหน) และข้อเสนอแนะ: การตั้งกฎแบบ **Threshold 1 มิติ (if/else)** นั้นหยาบเกินไป ทำให้เกิดข้อผิดพลาดบริเวณรอยต่อ (Boundary) ของข้อมูล นอกจากนี้
ตัวโมเดลยังคงพังเมื่อเจอสภาวะโจมตีแบบ A16 (Voice conversion ขั้นสูง) หากมีเวลาเพิ่มเติม ควรเปลี่ยนจากการใช้ Threshold ตัวเดียว ไปใช้ Machine Learning ขั้นพื้นฐาน (เช่น Logistic Regression หรือ K-Nearest Neighbors) เพื่อรองรับมิติของ MFCC หลายๆ
ตัวพร้อมกันแทนที่จะใช้เพียงสัมประสิทธิ์เดียว

การแบ่งงาน:

- **[คมสัน กลิ่นหอม]:** ศึกษาชุดข้อมูล ออกแบบสถาปัตยกรรม Pipeline
  รันโค้ดประเมินผลประสิทธิภาพและสกัดค่า Metrics ต่างๆ
- **[พรรสวกร สมใจ]:** ทำ Exploratory Data Analysis (EDA) สกัดกราฟ Waveform และ Spectrogram รวบรวมข้อมูลทั้งหมด เขียนรายงานฉบับสมบูรณ์